



**UNIVERSIDAD DE GUAYAQUIL**

**Facultad de Ciencias Matemáticas y Físicas**

**Tarea de Investigación y Práctica**

**Carrera:**

Ingeniería en Ciencia de Datos e IA

**Materia:**

Aprendizaje Automático

**Estudiante:**

Romina Salomé Vera Narváez

**Paralelo:**

CDDEIA-ELMA-4-1

**Docente:**

Msc. Darwin Rodríguez

**Fecha:**

13/6/2026

**Periodo:**

2025- 2026 CII

## Índice

|                                                                     |   |
|---------------------------------------------------------------------|---|
| Parte 1: Informe comparativo de Métricas .....                      | 3 |
| Introducción.....                                                   | 3 |
| Comparación de Métricas de Evaluación .....                         | 3 |
| Precisión .....                                                     | 3 |
| Recall (Sensibilidad) .....                                         | 3 |
| F1-Score .....                                                      | 3 |
| AUC-ROC .....                                                       | 4 |
| Justificación de la Métrica más Adecuada.....                       | 4 |
| Parte 3: Conclusiones Analíticas .....                              | 4 |
| ¿Qué método de búsqueda de hiperparámetros fue más eficiente? ..... | 4 |
| ¿Cómo afectó el ajuste del umbral a Precisión vs Recall? .....      | 4 |
| ¿y qué aprendiste sobre la elección de métricas? .....              | 4 |
| Bibliografía.....                                                   | 5 |

## Parte 1: Informe comparativo de Métricas

### Introducción

La clasificación automática de datos mediante algoritmos de aprendizaje automático tiene aplicaciones en distintos ámbitos como en el sector de la salud. En el diagnóstico de cáncer de mama, los modelos de clasificación pueden dar apoyo a los especialistas en identificar tempranamente los tumores malignos y benignos, ayudando a tomar decisiones rápidas y precisas.

No obstante evaluar el desempeño de un modelo no depende de conocer únicamente cuantas predicciones correctas realiza. Se necesita implementar métricas que permitan analizar diferentes aspectos de su comportamiento, como la capacidad para detectar casos positivos, evitar alarmas falsas o mantener el equilibrio entre ambos escenarios. Por ello en este informe se comparan las métricas Precisión, Recall, F1-Score y AUC-ROC aplicadas al problema de clasificación del conjunto de datos Breast Cancer Wisconsin.

### Comparación de Métricas de Evaluación

#### *Precisión*

Mide qué tan confiables son las predicciones positivas realizadas por el modelo. Se calcula mediante la relación  $TP / (TP + FP)$ , donde TP representa los verdaderos positivos y FP los falsos positivos. En nuestro modelo se obtuvo una precisión de 95.89%, lo que indica que la mayoría de los casos clasificados como positivos fueron correctos.

#### *Recall (Sensibilidad)*

Mide la capacidad del modelo para identificar correctamente los casos positivos reales. Su cálculo corresponde a  $TP / (TP + FN)$ , donde FN representa los falsos negativos. El modelo alcanzó un Recall de 97.22%, demostrando una alta capacidad para detectar los casos positivos presentes en el conjunto de datos.

#### *F1-Score*

Corresponde a la media armónica entre la Precisión y el Recall, calculándose como  $2 \times (Precision \times Recall) / (Precision + Recall)$ . Esta métrica permite evaluar el equilibrio entre ambas medidas. En nuestro modelo se obtuvo un F1-Score de 96.55%, reflejando un desempeño equilibrado y consistente.

## **AUC-ROC**

Mide la capacidad global del modelo para diferenciar entre las distintas clases considerando todos los posibles umbrales de decisión. Un valor cercano a 1 indica una excelente capacidad de discriminación. En nuestro modelo se obtuvo un AUC-ROC de 99.54%, evidenciando una excelente capacidad para distinguir entre tumores benignos y malignos.

## **Justificación de la Métrica más Adecuada**

Para el problema de clasificación de cáncer de mama, la métrica más importante es la Sensibilidad (Recall). Esta métrica permite identificar correctamente la mayor cantidad posible de casos positivos reales. En el ámbito médico, un falso negativo puede retrasar el diagnóstico y el tratamiento de un paciente. En nuestro modelo se obtuvo un Recall de 97.22%, evidenciando una alta capacidad de detección. Aunque métricas como Precision y F1-Score también son relevantes, Recall tiene una mayor importancia debido al riesgo asociado a no detectar un caso real de cáncer. Por ello, se considera la métrica más adecuada para este problema de clasificación.

## **Parte 3: Conclusiones Analíticas**

### **¿Qué método de búsqueda de hiperparámetros fue más eficiente?**

RandomizedSearchCV resultó más eficiente porque evaluó menos combinaciones de parámetros y requirió menos tiempo de procesamiento, manteniendo un rendimiento similar al de GridSearchCV.

### **¿Cómo afectó el ajuste del umbral a Precisión vs Recall?**

El ajuste del umbral mostró que existe un equilibrio entre Precisión y Recall. Un umbral más bajo favorece la detección de casos positivos, mientras que uno más alto mejora la confiabilidad de las predicciones.

### **¿y qué aprendiste sobre la elección de métricas?**

Se aprendió que una sola métrica no es suficiente para evaluar un modelo. Precision, Recall, F1-Score y AUC-ROC permiten analizar distintos aspectos del rendimiento y obtener una evaluación más completa.

## Bibliografía

- Berrar, D. (2019). Cross-Validation. Encyclopedia of Bioinformatics and Computational Biology. Obtenido de [https://dberrar.github.io/papers/Berrar\\_EBCB\\_2nd\\_edition\\_Cross-validation\\_preprint.pdf](https://dberrar.github.io/papers/Berrar_EBCB_2nd_edition_Cross-validation_preprint.pdf)
- Casal, R. F., Bouzas, J. C., & Fuente, M. O. (2024). *Métodos predictivos de aprendizaje estadístico*. Obtenido de Github: [https://rubenfcasal.github.io/aprendizaje\\_estadistico/aprendizaje\\_estadistico.pdf](https://rubenfcasal.github.io/aprendizaje_estadistico/aprendizaje_estadistico.pdf)
- Chicco, D., & Jurman, G. (2020). *The advantages of the Matthews correlation coefficient (MCC) over F1 score and accuracy in binary classification evaluation*. BMC Genomics. Obtenido de <https://link.springer.com/article/10.1186/s12864-019-6413-7>
- Esposito, D. (2024). *Introducción al aprendizaje automático*. Pearson Educación. <https://www.ebooks7-24.com/?il=37918>
- IBM. (2026). *What is logistic regression?* <https://www.ibm.com/topics/logistic-regression>
- Kelleher, A. (2024). *Aprendizaje automático en producción: desarrollo y optimización de flujos de trabajo de ciencias de datos y sus aplicaciones*. Pearson Educación. <https://www.ebooks7-24.com/?il=37920>
- Scikit-learn. (2026). *Cross-validation: Evaluating estimator performance*. [https://scikit-learn.org/stable/modules/cross\\_validation.html](https://scikit-learn.org/stable/modules/cross_validation.html)
- Scikit-learn. (2026). *Model evaluation: Quantifying the quality of predictions*. [https://scikit-learn.org/stable/modules/model\\_evaluation.html](https://scikit-learn.org/stable/modules/model_evaluation.html)